

Raport Przewodniczącego Obszaru: Cylindrical Flow Matching for Complex-Valued Medical Image Synthesis

Przedłożona do recenzji praca stanowi próbę rozwiązania fundamentalnego problemu w dziedzinie generowania obrazów medycznych, koncentrując się na syntezie w pełni zespolonych danych z rezonansu magnetycznego (MRI). Dokument ten został starannie przeanalizowany w kontekście celów warsztatów NeurIPS 2026: Geometric Distributional Deep Learning (GDDL) w Paryżu. Warsztaty te mają na celu budowanie mostów między geometrią różniczkową, uczeniem rozmaitości, optymalnym transportem (OT) a głębokim modelowaniem generatywnym i ustrukturyzowanymi dystrybucjami¹. Praca pt. „Cylindrical Flow Matching” idealnie wpisuje się w ten rygorystyczny zakres tematyczny, proponując odejście od naiwnych założeń euklidesowych w przestrzeni zespolonej na rzecz geometrycznie ugruntowanej rozmaitości cylindrycznej. W poniższym raporcie przedstawiono wyczerpującą, rygorystyczną recenzję typu peer-review, z pogłębioną analizą matematyczną, fizyczną oraz topologiczną zaprezentowanych metod, uwzględniającą najnowsze osiągnięcia w dziedzinie ciągłych przepływów normalizujących (Continuous Normalizing Flows) i teorii rozmaitości.

Podsumowanie

Autorzy proponują nowatorskie ramy generatywne dla zespolonych danych MRI, opierając się na metodzie Riemannian Flow Matching (RFM), gdzie sygnał modelowany jest na rozmaitości cylindrycznej $\mathbb{R}^+ \times S^1$, co pozwala na bezpośrednie uwzględnienie okresowej topologii fazy³. Dzięki zastosowaniu trygonometrycznego zanurzenia oraz dekonstrukcji metryki, model w naturalny sposób unika destruktywnej interferencji i tłumienia amplitudy, które nękają standardowe, euklidesowe modele generatywne³. Eksperymenty przeprowadzone na danych k-space z zestawu SKM-TEA potwierdzają przewagę tej geometrycznie świadomej metody, wykazując statystycznie istotną poprawę współczynnika PSNR oraz znaczącą redukcję błędów fazowych w porównaniu do płaskiej, euklidesowej przestrzeni odniesienia³.

Mocne Strony oraz Najważniejsze Aspekty Konceptyjne i Techniczne

Praca wykazuje wyjątkową dojrzałość koncepcyjną, skutecznie integrując abstrakcyjne pojęcia geometrii różniczkowej z praktycznymi wyzwaniami fizyki obrazowania medycznego.

Geometryczne Rozwiązanie Problemu Destruktywnej Interferencji

Najpoważniejszym osiągnięciem autorów jest precyzyjna identyfikacja i matematyczne rozwiązanie problemu tłumienia amplitudy w zespolonych modelach generatywnych. W standardowej przestrzeni euklidesowej $\mathbb{C} \cong \mathbb{R}^2$, liniowa interpolacja pomiędzy dwoma stanami z_0 i z_1 posiadającymi przeciwne fazy (np. $\theta_0 = 0$, $\theta_1 = \pi$) zmusza trajektorię prawdopodobieństwa do przejścia bezpośrednio przez początek układu współrzędnych³. Prowadzi to do niefizycznego tłumienia sygnału w trakcie procesu generatywnego, ograniczonego ściśle przez nierówność trójkąta. Autorzy wykazują, że przy jednorodnym rozkładzie fazy, oczekiwany spadek amplitudy w punkcie środkowym wynosi analitycznie 36.3% (co przekłada się na około 16% na skorelowanych przestrzennie danych MRI)³. Przeniesienie problemu na rozmaitość cylindryczną $\mathcal{M} = \mathbb{R}^+ \times S^1$ skutecznie dekomponuje składową radialną i kątową sygnału³. Wyposażając cylinder w metrykę produktową $g = dA^2 + d\theta^2$, autorzy wymuszają, by pole wektorowe transportowało fazę wzdłuż najkrótszej ścieżki na okręgu S^1 , całkowicie omijając osobliwość w punkcie zerowym. Jest to wysoce wyrafinowane zastosowanie podstaw teoretycznych nakreślonych przez Chen i Lipmana, udowadniające, że struktura rozmaitości odgrywa kluczową rolę w modelowaniu sygnałów o charakterze oscylacyjnym¹⁰.

Paradygmat Generatywny	Topologia Przestrzeni	Tłumienie Amplitudy	Obsługa Nieciągłości Fazy
Tradycyjne Modele Euklidesowe	$\mathbb{R}^2$ (Płaska)	Znaczne ($> 36\%$)	Brak obsługi
Zespolone Modele Dyfuzyjne (np. PhaseGen)	Zespolony Szum Gaussa	Umiarkowane	Pośrednia (poprzez warunkowanie)
Cylindrical Flow Matching (Zaproponowany)	$\mathbb{R}^+ \times S^1$ (Cylinder)	Całkowicie Wyeliminowane	Bezpośrednia (Zanurzenie)

Wykorzystanie Globalnego Układu Odniesienia

Wielkim wyzwaniem w modelach Riemannian Flow Matching (RFM) jest koszt obliczeniowy

związany z operowaniem na zakrzywionych rozmaitościach¹³. Geometrie o stałej, niezerowej krzywiznie (np. sfery czy przestrzenie hiperboliczne) wymagają ciągłego obliczania map eksponencjalnych, logarytmicznych oraz równoległego transportowania wektorów stycznych (parallel transport)¹¹. Autorzy dokonali znakomitego wyboru inżynierijno-matematycznego:

rozmaitość cylindryczna charakteryzuje się zerową krzywizną Riemanna ($K = 0$) oraz

trywialnym, globalnym polem odniesienia (global frame) $(\partial_A, \partial_\theta)$ ³.

Oznacza to, że sieć neuronowa może bezpośrednio regresować pole prędkości bez konieczności stosowania operatorów pushforward czy transportu równoległego, gwarantując wydajność obliczeniową identyczną z modelami euklidesowymi. Co więcej, w przeciwieństwie

do metryki biegunowej $g_{polar} = dA^2 + A^2 d\theta^2$, która wymusza osobliwość i niestabilność

numeryczną w pobliżu zera z powodu rosnącej prędkości kątowej $\mathcal{O}(A^{-1})$, metryka produktowa cylindra zapewnia, że docelowa prędkość kątowa jest globalnie ograniczona do

$|u_\theta| \leq \pi$ ³. Stanowi to solidny fundament dla stabilnego numerycznego szkolenia modeli.

Znaczenie dla Zespolonych Sieci Neuronowych i Rekonstrukcji MRI

Obrazowanie metodą rezonansu magnetycznego jest z natury procesem rejestrującym sygnały zespolone (k-space), a większość współczesnych algorytmów odrzuca informacje o fazie, skupiając się wyłącznie na amplitudzie³. Jednakże faza zawiera krytyczne informacje fizjologiczne (np. właściwości podatności magnetycznej, przepływy płynów) oraz odgrywa centralną rolę w rekonstrukcji z użyciem wielu cewek⁶. Autorzy słusznie zauważają zapotrzebowanie na syntetyczne, w pełni zespolone dane do wstępnego trenowania zaawansowanych sieci neuronowych. W tym kontekście praca stanowi znaczący krok naprzód w stosunku do istniejących alternatyw, takich jak PhaseGen, który wprowadza zespolony szum w modelach dyfuzyjnych, ale nie modeluje bezpośrednio topologii jako niezależnej struktury ewolucyjnej⁵. Przedstawiona metoda pozwala zaoferować wysoce ustrukturyzowany prior przestrzenny.

Słabe Strony i Nieścisłości Techniczne

Mimo doskonałego pomysłu wyjściowego, artykuł wykazuje szereg istotnych luk matematycznych, wprowadzając ad-hoc heurystyki, które nie mają uzasadnienia ani w fizyce obrazowania MRI, ani w teorii geometrycznego uczenia maszynowego. W kontekście rygoru akademickiego warsztatów GDDL, uchybienia te wymagają zdecydowanej poprawy.

Rozbieżność w Funkcji Straty: Norma L1 vs Niezmienniczość Geometryczna (L2)

Podstawową usterką teoretyczną jest zaproponowana w równaniu (2) funkcja straty:

$\mathcal{L} = \mathbb{E}[|v_A - u_A| + A_1 |v_\theta - u_\theta|]$ ³. Wykorzystanie normy L1 dla dopasowywania

wektorów w przestrzeni stycznej jest sprzeczne z fundamentalną teorią przepływów na rozmaitościach.

W metodologii Flow Matching, wierność modelu zależy od minimalizacji oczekiwanej różnicy między wektorem predykowanym a wektorem docelowym mierzonym przy użyciu kwadratu

normy Riemanna w lokalnej przestrzeni stycznej $\|v - u\|_g^2$ ²⁰. Zastosowanie normy L2 jest bezpośrednio powiązane z minimalizacją energii kinetycznej ścieżki prawdopodobieństwa, co gwarantuje, że indukowany przepływ marginalny jest tożsamy z przepływem optymalnego

transportu, optymalizując odległość Wassersteina (W_2)²². Chociaż w literaturze dotyczącej przyspieszania generacji euklidesowej (np. *L1 Flow*) argumentuje się, że zastosowanie straty L1 poprawia odporność na zapaść modów (mode collapse) w procesach jednoetapowych²⁵, przeniesienie tego empirycznego zabiegu na pęczki styczne (tangent bundles) rozmaitości Riemanna niszczy równoważność z równaniem ciągłości przepływu marginalnego²⁷. Autorzy nie dostarczają żadnego dowodu, że użycie straty L1 zachowuje właściwości całkujące pola wektorowego dla rozmaitości.

Kryterium Teoretyczne	Przestrzeń Euklidesowa	Rozmaitość Riemanna (Wymagania)	Wybór Autorów	Skutek
Metryka Straty	Dowolna (L1/L2)	L2 (Kwadrat Metryki Riemanna)	L1	Utrata powiązania z energią kinetyczną i OT
Optymalny Transport	Odległość W_1 / W_2	Odległość Geodezyjna W_2	Niezdefiniowan a topologicznie	Zaburzone ewolucje dystrybucji na cylindrze

Błędna Interpretacja Matrycy Informacyjnej Fishera

Autorzy twierdzą, że modulacja straty dla fazy docelową amplitudą A_1 funkcjonuje jako „Fisher-information variance reduction weighting”³. Jest to stwierdzenie fałszywe z punktu widzenia fizyki szumu w aparatach MRI.

W zespolonych pomiarach rezonansu magnetycznego termiczny szum elektroniczny modelowany jest jako zespolony Addytywny Biały Szum Gaussa (AWGN), gdzie zarówno część

rzeczywista, jak i urojona charakteryzują się jednakową wariancją σ^2 ²⁸. W wyniku tego, wielkość (amplituda) sygnału podlega rozkładowi Riciana³⁰. Analiza macierzy informacji Fishera dla rozkładu Riciana (lub jego aproksymacji w warunkach wysokiego stosunku sygnału do

szumu - SNR) wykazuje, że informacja związana z fazą skaluje się proporcjonalnie do kwadratu amplitudy względem wariancji szumu: $\mathcal{I}_{\theta\theta} \propto A^2/\sigma^2$ ³². W związku z tym, prawdziwie geometryczne ugruntowanie metryki opartej o informację Fishera wymagałoby zastosowania kwadratowego czynnika ważącego (np. A_1^2 przy stracie L2). Liniowa waga

zastosowana przez autorów (A_1 przy stracie L1) to wyłącznie heurystyka inżynierska, która nie ma uzasadnienia w statystyce i gubi płynne przejście pomiędzy topologią biegunową w rejonach wysokiego SNR a czystym szumem w rejonach braku sygnału tła³⁴.

Osobliwość na Początku Układu (Origin Singularity) i Sztuczne Brzegi

Zdefiniowanie rozmaitości jako $\mathbb{R}^+ \times S^1$ sprawia, że punkt, w którym amplituda wynosi zero ($A = 0$), stanowi patologię. Faza staje się w nim matematycznie niezdefiniowana⁴. Autorzy

ignorują ten problem, wprowadzając prymitywne sprzętowe obcięcie (clamp) $\epsilon = 10^{-6}$ ³. W kontekście głębokiego uczenia geometrycznego (GDDL), takie podejście jest wysoce krytykowane. Zastosowanie obcięcia tworzy sztuczny brzeg rozmaitości (manifold boundary). W teorii Flow Matching na rozmaitościach z brzegiem, konieczne jest sformułowanie specjalnych warunków brzegowych (np. Neumanna lub brzegów odbijających), aby pole wektorowe nie wypychało prawdopodobieństwa poza zdefiniowany obszar³⁶. Ominięcie tego faktu oznacza, że numeryczna integracja ODE w obszarach zdominowanych przez szum (np. tło powietrza wokół tkanki w MRI) będzie prowadzić do kumulacji mas na sztucznym brzegu ϵ .

Nadinterpretacja Związku z Optymalnym Transportem na S^1

W linii 73 autorzy wskazują, że zaproponowana przez nich metryka tworzy pomost do "Optimal Transport na S^1 w formie zamkniętej", przywołując pracę Delon et al. z 2010 roku³. Ta afirmacja wprowadza w błąd.

Praca Delon i wsp. odnosi się do wyznaczania dokładnej 1-odległości Wassersteina (W_1) na okręgu dla pełnych rozkładów marginalnych, co sprowadza się do wyznaczenia globalnie optymalnego przesunięcia rzędu poprzez przesunięcie dystrybucyj (circular CDF shift) i znalezienie tzw. *level median*, który rozwiązuje problem okresowego zapętlenia³⁹. Równanie (1) autorów polega tymczasem jedynie na obliczeniu trywialnej różnicy kątowej z użyciem funkcji atan2 ³. Jest to po prostu analityczne rozwiązanie równania geodezyjnego dla dwóch *niezależnych* punktów próbkowanych z bazy i celu. Bez zdefiniowania schematu parowania minimalizującego globalny koszt transportu (jak Minibatch OT lub pełne rozwiązanie Wassersteina), model uczy się niezależnych ścieżek warunkowych, a nie globalnego planu optymalnego transportu (Optimal Transport Plan).

Zbytnie Uproszczenie Zgodności Danych (Data Consistency) z MRI

Przedstawiona ewaluacja, choć potwierdza zdolność modelu do generacji, opiera się na radykalnym uproszczeniu fizyki akwizycji. Dataset SKM-TEA zawiera wielocewkowe pomiary wolumetryczne (3D qDESS)⁶. Autorzy dokonali redukcji do wyizolowanego sygnału pojedynczej cewki (single-coil)³.

Działanie algorytmów rekonstrukcyjnych z przeplotem projekcji k-space (k-space data consistency) w prawdziwym środowisku medycznym opiera się na operatorach SENSE, które wymuszają nieliniowe mieszanie faz pomiędzy kanałami cewek⁶. W klasycznym,

jednocewkowym modelu rekonstrukcja fazy jest zadaniem trywialnym w porównaniu do środowisk klinicznych, w których występuje szum skorelowany pomiędzy cewkami.

Stwierdzenie, że technika oferuje bazowy, fizycznie spójny fundament generatywny dla pełnych danych zespolonych ("geometrically grounded baseline for complex-valued MRI generation"), jest przedwcześnie, dopóki model nie udowodni odporności na topologiczne zawirowania rzutowania przestrzennego wielocewkowego operatora do przodu.

Brak Uwzględnienia Pól Jacobiego i Kary za Krzywiznę

Zakładając płaski cylinder (zerowa krzywizna), autorzy nie zważają na najnowsze osiągnięcia na polu Riemannian Gaussian Variational Flow Matching (RG-VFM)²¹. RG-VFM udowadnia, że w zakrzywionych przestrzeniach wariancja fazy powinna podlegać karze zależnej od krzywizny, często modelowanej za pomocą pól Jacobiego (Jacobi fields)¹⁵. Ponieważ w zespolonym sygnale MRI przy spadającej amplitudzie wariancja fazy wzrasta dążąc do rozkładu jednorodnego³⁰, czysto płaski układ odniesienia zmusza się do modelowania losowego dryfu fazowego ze sztucznie nałożoną wysoką ufnością w rejonach tła.

Pytania do Autorów

Aby właściwie ustosunkować się do zasygnalizowanych problemów teoretycznych oraz heurystyk zaprezentowanych w dokumencie, przed wydaniem ostatecznej wiążącej opinii, autorzy proszeni są o szczegółowe odniesienie się do poniższych pytań w trakcie fazy *rebuttal*:

1. Zgodność teoretyczna warunkowego przepływu z metryką L1: Równanie (2)

implementuje uczenie pola prędkości (velocity matching) poprzez minimalizację różnicy w normie L1 na pęczkach stycznych cylindra. Jednak podstawowe twierdzenia teoretyczne Continuous Normalizing Flows na rozmaitościach wiążą pole prędkości z równaniem ciągłości i minimalizacją energii kinetycznej wyłącznie przy wykorzystaniu kwadratu metryki Riemanna (normy L2). W jaki sposób możecie Państwo matematycznie dowieść, że zastosowana obiektywna funkcja L1 indukuje prawidłowy, zgodny z geometrią rozmaitości przepływ marginalny dla ustrukturyzowanych ścieżek?

2. Zastosowanie Macierzy Informacyjnej Fishera a rzeczywisty model szumu MRI: Użyty w pracy wskaźnik ważący straty fazowej polega na liniowym modulowaniu za pomocą docelowej

amplitudy A_1 . Ponieważ szum elektroniczny zespolonego sygnału k-space posiada charakter Gaussa (co przekłada się na rozkład Riciana dla magnitudy), informacja Fishera względem

wariancji fazy powinna wzrastać z kwadratem amplitudy (A^2/σ^2). Na jakiej podstawie twierdzą Państwo, że liniowa waga oddaje wkład Fishera? Czy próbowano uczyć model w oparciu o naturalną wagę kwadratową, a jeśli tak, czy napotkano problemy ze stabilnością numeryczną na wczesnych etapach uczenia gradientowego?

3. Fizyczna spójność i topologiczna osobliwość tła (Origin Singularity):

Heurystyczne ucięcie wartości na poziomie $\epsilon = 10^{-6}$ generuje sztuczny brzeg, stwarzając ryzyko uwięzienia masy prawdopodobieństwa na krańcach rozmaitości podczas operacji ODE. Ponieważ całkowity brak sygnału z obszaru pozatankowego w MRI odzwierciedla zachowanie szumu sprzętowego, dlaczego zdecydowali się Państwo na wprowadzanie szumu bazy ze sztucznego, jednostajnego rozkładu na przedziale obcięty, zamiast wykorzystać dystrybucję Rayleigha w warstwie amplitudy, która naturalnie osiąga gęstość zerową w centrum, zachowując spójność fizyczną?

4. Optymalny Transport a niezależne ścieżki geodezyjne: Choć powołujecie się Państwo na pracę Delon et al., która rozwiązuje globalny plan optymalnego sprzężenia na okręgu z użyciem median z przesunięciem dystrybuanty (CDF), model najwyraźniej ogranicza się jedynie do liczenia odległości atan2 dla stochastycznie niesparowanych, dyskretnych par z bazy i rozkładu docelowego. Czy stosują Państwo jakikolwiek ukryty mechanizm dopasowania wewnątrz mini-wsadu (Minibatch Optimal Transport) wspierający tworzenie rzetelnego, globalnego planu kosztów dla okręgu, czy jest to wyłącznie sformułowanie niezależnych ścieżek geodezyjnych na rozmaitości produktu?

Ocena Ogólna i Rekomendacja

Ogólna Punktacja: 7/10 **Rekomendacja:** Akceptacja (Accept)

Uzasadnienie Rekomendacji: Przedstawiona praca rzuca nowe światło na niezwykle powszechny, a mimo to notorycznie ignorowany problem związany z zastosowaniem sieci neuronowych w domenach operujących liczbami zespolonymi – zjawisko euklidesowego tłumienia amplitudy przy przeciwfazowej interpolacji. Zaproponowane rozwiązanie polegające na dekonstrukcji sygnału na rozmaitość cylindryczną jest wybitne z perspektywy swojej koncepcyjnej prostoty, elegancji i bezpośredniej użyteczności dla społeczności przetwarzania sygnałów rezonansu magnetycznego. Jest to idealny materiał pasujący do celów warsztatów Geometric Distributional Deep Learning. Wykazano w sposób rzetelny i statystycznie spójny, że cylindryczne formowanie rzutuje na lepszą rekonstrukcję i redukcję cyrkularnego błędu fazy w architekturze dyfuzyjnej typu Flow Matching w odniesieniu do klasycznej płaskiej przestrzeni. Niestety, dokument wymaga poprawek technicznych wynikających ze swobody analitycznej w konstruowaniu modelu matematycznego. Niezrozumiałe z punktu widzenia geometrii różniczkowej przyjęcie funkcji straty opartej na normie L1 na rzecz poprawnej L2 dla rozmaitości Riemanna, posiłkowanie się heurystycznymi klipami w celu zamaskowania osobliwości punktu zerowego topologii z obszarów pozbawionych sygnału oraz pochopne przypisywanie liniowym skalarom miana modelowania Fishera to potknięcia, które odbierają pracy pełny rygor teoretyczny, właściwy prestiżowym ścieżkom publikacyjnym (Oral/Best Paper). Praca na pewno sprowokuje fascynujące dyskusje w sekcji plakatowej, lecz wymaga uzupełnienia o ściśle

argumenty fizyczne i poprawę wzorów optymalizacyjnych. Ze względu na potencjał wpływu, z pełnym przekonaniem zalecam jej publikację na warsztatach po uwzględnieniu rewizji matematycznej.

Rekomendacje Działań Niezbędnych do Osiągnięcia Maksymalnej Oceny (Oral / Best Paper)

W celu zapewnienia najwyższego możliwego standardu technicznego, gotowego do uznania pracy jako kandydata do nagrody *Best Paper*, zachęcam do zrewidowania i modyfikacji tekstu zgodnie z poniższymi wytycznymi w finalnej wersji pracy (Camera-Ready):

1. Korekta Metryki Riemanna we Wzorze na Stracie (L2 Loss)

Działanie: Konieczna jest modyfikacja Równania (2) tak, aby odzwierciedlało prawdziwą formę energii kinetycznej wymaganej do regresji pola przepływu marginalnego (Riemannian Continuous Normalizing Flows).

W obecnej formie, równanie oparte o L1 jest niezgodne z wymogiem zachowania niezmienniczości względem lokalnego iloczynu skalarnego przestrzeni stycznej¹². Równanie musi zostać skorygowane na wariant oparty o L2:

$$\mathcal{L}_{RFM} = \mathbb{E} \left[(v_A - u_A)^2 + \frac{A_1^2}{\sigma^2} (v_\theta - u_\theta)^2 \right]$$

Ta prosta zamiana dokonuje jednocześnie dwóch poprawek teoretycznych: naprawia podstawę geometryczną algorytmu Riemannian Flow Matching¹⁰ oraz faktycznie spełnia wymóg precyzyjnego pozycjonowania zredukowanej wariancji Fishera dla szumu o strukturze

Gausa/Riciana (gdzie faza ma wariancję asymptotycznie dążącą do σ^2/A^2).

2. Rozwiązanie Problemu Osobliwości Zera poprzez Zmianę Dystrybucji Bazy

Działanie: Należy wyeliminować нефизyczny i topologicznie inwazyjny limit klipowania $\epsilon = 10^{-6}$. Najbardziej eleganckim rozwiązaniem w ujęciu teorii przepływów byłaby zmiana

samego rozkładu początkowego p_0 . Zamiast obciętego jednostajnego cylindra bazowego, należy zastosować fizycznie motywowany sygnał tła szumu MRI, tj. model Rayleigha w warstwie amplitudowej:

$$A_0 \sim \text{Rayleigh}(\sigma), \quad \theta_0 \sim \mathcal{U}(S^1)$$

Zaletą rozkładu Rayleigha jest to, że jego prawdopodobieństwo naturalnie osiąga gęstość

zerową w samym początku układu ($A \rightarrow 0$). Całkowicie wyeliminuje to pojawianie się próbek źródłowych dokładnie w osobliwości topologicznej bez konieczności stosowania нефизycznych

uciąć brzegów rozmaitości³⁰. Taka zamiana w architekturze podniesie wiarygodność dokumentu, harmonizując inżynierię uczenia z rzeczywistym modelowaniem szumu fizycznego tła.

3. Usunięcie Zbyt Szerokiej Deklaracji o Optymalnym Transporcie na Okręgu

Działanie: Ograniczenie lub zmiana opisu w sekcji 2 w odniesieniu do pracy *Delon et al., 2010*³⁸. Zastosowanie w pracy prostej, wektorowej wyznaczalności różnicy geodezyjnej (atan2) nie rozwiązuje globalnego planu optymalnego sprzęgnięcia dla pełnego rozkładu marginalnego. Proponuję zmodyfikować linię 73 na następującą formę narracyjną: „*Metryka dekomponuje składowe sygnały, umożliwiając przepływowi ściśle korzystanie z geodezyjnych ścieżek najkrótszych na S^1 . Zapewnia to geometryczne podwaliny do ewentualnego wdrażania zaawansowanych protokołów Minibatch Optimal Transport dla zmiennych kątowych, minimalizując straty transportu krzywizn.*”

4. Zastosowanie Wielocewkowego Modelu Zgodności Danych (Multi-Coil Data Consistency)

Działanie: Jeśli to możliwe w fazie korekty (lub w przyszłych pracach rozszerzających algorytm), należy odnieść się do wdrożenia eksperymentu na wielu cewkach (dostępnego natywnie w zbiorze SKM-TEA) w sekcji 3⁶.

Proces rzutowania naprzemiennego k-space dla obrazowania równoległego obejmuje nieodwracalną fazową interferencję SENSE pomiędzy sprzężonymi mapami przestrzennymi cewek⁴². Wprowadzenie modyfikacji bloku Data Consistency uwzględniającej operator SENSE ostatecznie zamknęłoby lukę w ocenie jakości rekonstrukcyjnej, dowodząc, że rozmaitość cylindryczna przetrwa silne nieliniowe zniekształcenia faz w zaawansowanych algorytmach optymalizacji. Odpowiednia adnotacja o tych efektach fizycznych znacząco ugruntowałaby pracę jako pionierski paradygmat.

Cytowane prace

1. Geometric Distributional Deep Learning | NeurIPS 2026 Workshop, <https://gddl-neurips-2026.github.io/>
2. Rémi Flamary — The Who's Who of AI | AI Weekly, <https://aiweekly.co/whos-who/person/rflamary-bsky-social>
3. Untangled_Complex_Flow_Matching-2.pdf
4. Flow Matching on General Geometries - arXiv, <https://arxiv.org/html/2302.03660v3>
5. A Diffusion-Based Approach for Complex-Valued MRI Data, <https://www.themoonlight.io/en/review/phasegen-a-diffusion-based-approach-for-complex-valued-mri-data-generation>
6. SKM-TEA: A Dataset for Accelerated MRI Reconstruction with Dense, https://www.researchgate.net/publication/359227312_SKM-TEA_A_Dataset_for_Accelerated_MRI_Reconstruction_with_Dense_Image_Labels_for_Quantitative_Cli

nical_Evaluation

7. Computer Science - arXiv, <https://www.arxiv.org/list/cs/new?skip=150&show=1000>
8. PhaseGen: A Diffusion-Based Approach for Complex-Valued MRI, <https://arxiv.org/html/2504.07560v1>
9. Sliced Optimal Transport on the Sphere - arXiv, <https://arxiv.org/html/2304.09092v2>
10. Flow Matching on General Geometries - Weizmann Institute of Science, <https://weizmann.elsevierpure.com/en/publications/flow-matching-on-general-geometries/>
11. Riemannian MeanFlow for One-Step Generation on Manifolds - arXiv, <https://arxiv.org/html/2603.10718v2>
12. FLOW MATCHING ON GENERAL GEOMETRIES - OpenReview, <https://openreview.net/notes/edits/attachment?id=FxEKZeftXQ&name=pdf>
13. BrainFlow: A Holistic Pathway of Dynamic Neural System on Manifold, https://papers.nips.cc/paper_files/paper/2025/file/2e098001625a8b8f22bf6c1aef09c4e5-Paper-Conference.pdf
14. Wasserstein Flow Matching: Generative Modeling Over Families of, <https://raw.githubusercontent.com/mlresearch/v267/main/assets/haviv25a/haviv25a.pdf>
15. Comparison Theorems in Riemannian Geometry | Request PDF, https://www.researchgate.net/publication/401475542_Comparison_Theorems_in_Riemannian_Geometry
16. PhaseGen: A Diffusion-Based Approach for Complex-Valued MRI, <https://mml.ikim.nrw/publications/rempe-phasegen-2025/>
17. MRI denoising via phase error estimation - ResearchGate, https://www.researchgate.net/publication/228369036_MRI_denoising_via_phase_error_estimation
18. PhaseGen: A Diffusion-Based Approach for Complex-Valued MRI, <https://arxiv.org/abs/2504.07560>
19. PhaseGen: A Diffusion-Based Approach for Complex-Valued MRI, <https://www.alphaxiv.org/abs/2504.07560v1>
20. Riemannian Conditional Flow Matching - Emergent Mind, <https://www.emergentmind.com/topics/riemannian-conditional-flow-matching-rcfm>
21. Riemannian Variational Flow Matching for Material and Protein Design, <https://arxiv.org/html/2502.12981v2>
22. (PDF) Riemannian Convex Potential Maps - ResearchGate, https://www.researchgate.net/publication/352559576_Riemannian_Convex_Potential_Maps
23. An Error Analysis of Flow Matching for Deep Generative Modeling, <https://icml.cc/virtual/2025/poster/43685>
24. An Error Analysis of Flow Matching for Deep Generative Modeling, <https://raw.githubusercontent.com/mlresearch/v267/main/assets/zhou25l/zhou25l.pdf>
25. Let EEG Models Learn EEG - OpenReview, <https://openreview.net/forum?id=TP8OuKKmsf>

26. L1 Sample Flow for Efficient Visuomotor Learning - arXiv, <https://arxiv.org/html/2511.17898v1>
27. Total Variation Rates for Riemannian Flow Matching - arXiv, <https://arxiv.org/pdf/2602.05174>
28. How to measure SNR - Questions and Answers in MRI, <https://mriquestions.com/signal-to-noise.html>
29. (PDF) MRI denoising with a non-blind deep complex-valued, https://www.researchgate.net/publication/385725857_MRI_denoising_with_a_non-blind_deep_complex-valued_convolutional_neural_network
30. Data Science: Time Complexity, Inferential Uncertainty, and, <https://dokumen.pub/data-science-time-complexity-inferential-uncertainty-and-space-time-analytics-9783110697827-9783110697803.html>
31. The Rician distribution of noisy MRI data - PubMed - NIH, <https://pubmed.ncbi.nlm.nih.gov/8598820/>
32. The Information Dynamics of Generative Diffusion - PMC - NIH, <https://pmc.ncbi.nlm.nih.gov/articles/PMC12939406/>
33. (PDF) Why Heuristic Weighting Works: A Theoretical Analysis of, https://www.researchgate.net/publication/394293829_Why_Heuristic_Weighting_Works_A_Theoretical_Analysis_of_Denoising_Score_Matching
34. The Rician Distribution of Noisy MRI Data - PMC - NIH, <https://pmc.ncbi.nlm.nih.gov/articles/PMC2254141/>
35. NeurIPS Poster Riemannian Consistency Model, <https://neurips.cc/virtual/2025/poster/117955>
36. Flow Matching: Guide and Code | PDF - Scribd, <https://www.scribd.com/document/807996074/Flow-matching-guide-and-code>
37. Interior-point methods on manifolds: theory and applications, https://www.researchgate.net/publication/376776456_Interior-point_methods_on_manifolds_theory_and_applications
38. Optimal Transport for Machine Learners - of Gabriel Peyré, <https://www.gpeyre.com/ot4ml/compact/CourseOT-compact.pdf>
39. Spherical Sliced-Wasserstein - arXiv, <https://arxiv.org/html/2206.08780v2>
40. Partial Optimal Transport on the Circle for All Transported Masses in, <https://arxiv.org/html/2608.23910v1>
41. A Generative Framework for MIMO Channel Estimation - arXiv, <https://arxiv.org/html/2601.15767v3>
42. A review and experimental evaluation of deep learning methods for, <https://pmc.ncbi.nlm.nih.gov/articles/PMC9202830/>
43. [PDF] Riemannian Variational Flow Matching for Material and, <https://www.semanticscholar.org/paper/Riemannian-Variational-Flow-Matching-for-Material-Zaghen-Eijkelboom/96ff331aa2305dd5de84ce31d54bab8af107b3fe>
44. Riemannian Variational Flow Matching for Material and Protein Design, <https://openreview.net/forum?id=NlnDseIrtI>
45. A Review on Image Reconstruction through MRI k-Space Data, https://www.researchgate.net/publication/281618323_A_Review_on_Image_Reconstruction_through_MRI_k-Space_Data

46. Trajectory Stitching for Solving Inverse Problems with Flow-Based,
<https://arxiv.org/html/2602.08538v1>